베스트셀러 리뷰 분석

C321044 유정원 C321059 이화영
C321060 임효빈 C321062 장하영

2025-2 텍스트마이닝 TMI조

목 차

Ⅰ

주제 소개

- 주제 선정 배경
- 목표

Ⅱ

데이터

- 데이터 수집 방법
- 데이터 전처리

Ⅲ

분석 과정

- 분석 프레임 워크
- 분석 과정

Ⅳ

결과 분석

- 인사이트 도출
- 응용 모델 제안 및 분석

Ⅴ

최종 결론

- 결론

Ⅵ

Appendix

- 분석 과정에서 한계점
- 개선 방안

I. 주제 소개

선정 배경 및 목표

Best Seller

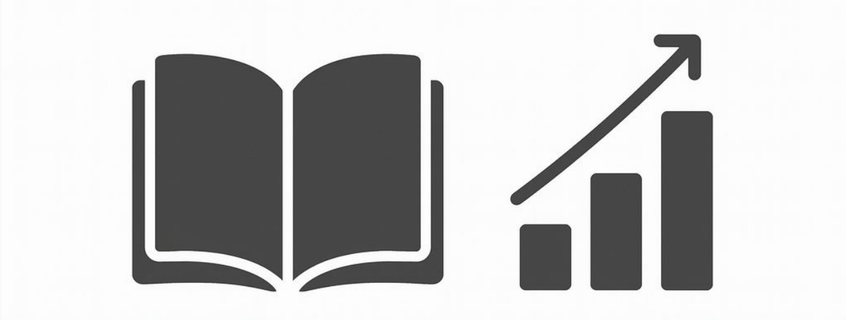

- **선정 배경:**

  베스트셀러 순위는 ‘얼마나 많이 팔렸는가’를 보여주는 정량적 지표

➔ 독자가 ‘얼마나 만족했는가’,

‘왜 이 책을 읽었는가’까지는 설명 불가

- **프로젝트 목표:**

1. 키워드로 보는 연도별 트렌드
2. '베스트셀러 거품’ 탐지
3. 장르를 넘어선 '토픽' 기반의 새로운 도서 추천 모델 제시

II. 활용 데이터

데이터 전처리 및 통합

알라딘

❶ 불필요 컬럼 제거 ❷ 별점 정규화

	A	B	C	D	E	F	G	H	I
1	title	author	publisher	category	a_review_type	a_review_tex	a_rating	a_user	a_review_date
2	117층 나무	앤디 그리	시공주니어	어린이	100자평	벌써부터 120	5점	데이지	2020-01-10
3	117층 나무	앤디 그리	시공주니어	어린이	100자평	층이 높아질수	5점	tboz78	2020-01-12
4	117층 나무	앤디 그리	시공주니어	어린이	100자평	베스트셀러의	5점	una	2020-03-10
5	117층 나무	앤디 그리	시공주니어	어린이	100자평	아이가 초등학	5점	loginzero	2023-03-21

❸ 날짜 형식 정규화

교보문고

	A	B	C	D	E	F	G	H	I	J
1	title	author	publisher	category	k_review_tex	k_rating	k_review_keyword	k_review_badges	k_review_date	k_user
2	117층 나무	앤디 그리	시공주니어	어린이	꾸준히 읽는	4점	잘읽어요	종이책, 구매자	2020.07.31	mi******
3	117층 나무	앤디 그리	시공주니어	어린이	깔깔깔 뒤집어	4점	유익해요	종이책, 구매자	2020.07.30	se*******
4	117층 나무	앤디 그리	시공주니어	어린이	좋아요 잘구매	4점	좋아해요	종이책, 구매자	2020.07.28	ki******
5	117층 나무	앤디 그리	시공주니어	어린이	야들이 동아 하	4점	재밌어요	종이책, 구매자	2020.07.26	ec*****

교집합 목록

A	B	C	D	E	F	G	H	I	J
aladin_rank	kyobo_rank	title	aladin_productcode	kyobo_productcode	ISBN	author	publisher	pub_date	category
112	94	117층 나무 집	222102869	S000000731166	9788952744586	앤디 그리피스	시공주니어	20200110	어린이
54	12	1cm 다이빙	228695400	S000001938499	9791190299060	태수 외	피카(FIKA)	20200121	소설/시/희곡/에세이
60	24	1일 1페이지, 세상에서 가장 짧은 교양 수업 365	214116947	S000001938651	9791190305679	데이비드 s. 키더 외	위즈덤하우스	20191030	인문학
119	82	공간이 만든 공간	237766385	S000000576557	9788932474274	유현준	을유문화사	20200501	인문학

두 플랫폼의 베스트셀러 정보 통합->연도별 베스트셀러 교집합 파일 생성

도서/리뷰 DB 생성

- 도서 기본정보 DB - 컬럼명

ISBN	title	title_key	author	publisher	pub_date	category
9791190000000	28시간에 끝내는	28시간에끝내는ㅌ	황인기.시원	시원스쿨L/	20250325	외국어

aladin_productcode	kyobo_productcode	bestseller_year	n_bestseller_years	aladin_rank_by_year	kyobo_rank_by_year
361172981	S000001893506	[2023, 2024]	2	{"2023": 218, "2024":	{"2023": 190, "2024": 187}

각 연도별 파일로 분산되어있던 베스트셀러 정보를 하나의 도서 DB로 추합 ⇒ 총 460권의 도서 기본 정보 저장

- 리뷰 DB

나를 소모하지 않는 현명한 태도에 관하여_9791198682505_review.csv

site	title_norm	file_title	review_text	rating_5pt	review_date
kyobo	나를소모하지않는현명한		읽는 중인데	2.5	2024-04-17
kyobo	나를소모하지않는현명한		빈약한 내용	1.25	2024-04-19
aladin	나를소모하지	나를 소모	더 성공해야	4	2024-04-03
aladin	나를소모하지	나를 소모	프롤로그 첫	4	2024-07-14

사이트 분류 항목 추가

*리뷰 DB의 파일명: ***{도서 제목}_{ISBN}_review 형식***

→ "**ISBN**"을 key로 도서 DB와 매핑하여 사용

각 연도•사이트별로 분산되어있던 리뷰 데이터를 도서별 리뷰 파일로 병합 ⇒ 460권에 대한 약 17만 개의 리뷰 데이터 저장

III. 분석 과정

분석 프레임워크

STEP 1

데이터 수집

- 베스트셀러 메타데이터 수집
- 리뷰 데이터 크롤링 (Selenium 활용)

STEP 2

데이터 전처리

- 메타데이터 전처리
- 도서/리뷰 DB 생성
- 텍스트 데이터 정제
- 분석용 변수 생성 (감성지수 등)

STEP 3

분석 & 시각화

- 기본 분석
- 감정 분석
- 데이터 시각화

STEP 4

인사이트 도출

- 스테디 vs. 단발성의 차이
- 연도별 키워드 변화
- 거품 탐지
-

텍스트데이터 전처리

1) 제목 정규화

```
def normalize_title(s):
    s = str(s).strip()
    s = re.sub(r"₩s+", "", s)
    s = re.sub(r"[^가-힣A-Za-z0-9()]", "", s)

    return s.lower()
```

2) 불용어 및 토큰화 제외 대상 용어 정의

```
# 불용어(Stopwords) 리스트 정의
stopwords = {
    '책','작가','저자','구매','주문', '배송', '도서', '리뷰','서평','발송',
    'yes24','교보문고' '내용','포장','이야기',
    '읽다','읽히','그것','무엇',
    '그', '이', '저', '것', '수', '등', '들','때', '거', '해서',
    '하지만', '그리고', '그래서',
    '이다', '보다','보는',
    '그냥','사실','개인적으로','솔직히',
    '왠만해선','정말로'
}
```

*도서 리뷰에서 자주 쓰이거나 분석에 불필요한 용어 불용어로 정의

```
for w in ["자기 계발", "자기계발", "퍼스널브랜딩", "리브랜딩",
          "브랜딩", "강추","비추","최애","흔한 남매","흔한남매"]:
    kiwi.add_user_word(w, "NNG")
```

*e.g. ‘강추’-> [‘강’, ‘추’]로 토큰화되는 경우 발견.
유사한 상황의 단어들 토큰화 제외 대상으로 정의함.

3) Kiwi 토크나이저 사용하여 토큰화 수행

```
kiwi.tokenize(text_cleaned)
```

```
['NNG', 'NNP', 'VV', 'VA', 'XR', 'MAG', 'SL']
```

긍/부정 분류 - KNU 한국어 감성 사전 기반

Token화 된 리뷰 DB 파일을 사용 + KNU 한국어 감성 사전기반 긍/부정 이진 분류 모델 구성

- 복합 감성 표현 (N-gram)을 우선 매칭
- 부정, 강조 규칙을 적용해 감성 점수 계산

review_text	sent_binary
저는 별로지만.. 애가좋아해서.. 이제 이거 안나왔음 좋겠어요...	1

: 부정적인 리뷰이나 긍정으로 판단

review_text	sent_binary
미리 읽어볼 껄 하는 뒤늦은 후회가~ 꼭 읽어보세요!!	0

: 긍정적인 리뷰이나 부정으로 판단

*긍정=1
*부정=0

→ 'KNU 사전'으로는 전체적인 맥락 파악이 어려움

긍/부정 분류 - KoELECTRA 모델

KoELECTRA 란?

- ELECTRA 구조를 기반으로 한 한국어 사전학습 언어모델
- BERT 대비 효율적이고 빠른 학습/추론이 특징

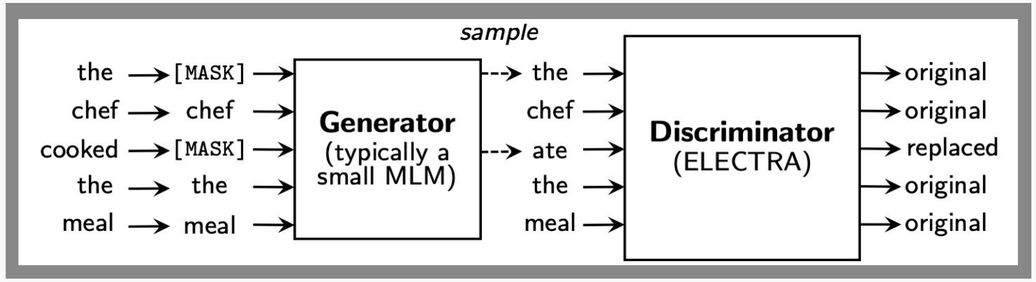

*ELECTRA의 구조: generator에서 나온 token을 보고 discriminator에서 'real'토큰과 'fake'토큰을 판별하며 학습함.
모든 input token에 대해 학습할 수 있다는 장점을 가지며, BERT 등과 비교했을 때 더 좋은 성능을 보임.

```
MODEL_NAME = "monologg/koelectra-small-finetuned-nsmc"
```

→ NSMC (네이버 영화 리뷰) 데이터로 감성 분류 fine-tuning 된 KoELECTRA 모델 사용

https://github.com/monologg/KoELECTRA?source=post_page-----1a23a0c704af---------- / https://huggingface.co/monologg/koelectra-base-finetuned-nsmc

긍/부정 분류 - KoELECTRA 모델

- 입력 문장의 문맥 정보를 바탕으로 긍/부정을 분류
- 모델 출력: logits (부정/긍정 점수)
- softmax 적용 후 확률로 변환 → 긍정 클래스 확률을 기준으로 긍/부정 이진 분류

KNU 사전 기반 분류 결과

review_text	sent_binary
저는 별로지만.. 애가좋아해서.. 이제 이거 안나왔음 좋겠어요...	1

review_text	sent_binary
미리 읽어볼 껄 하는 뒤늦은 후회가~ 꼭 읽어보세요!!	0

KoELECTRA 모델 분류 결과

review_text	sent_label	sent_label_name
저는 별로지만.. 애가좋아해서.. 이제 이거 안나왔음 좋겠어요...	0	negative

review_text	sent_label	sent_label_name
미리 읽어볼 껄 하는 뒤늦은 후회가~ 꼭 읽어보세요!!	1	positive

사전 기반 분류보다 맥락 파악을 잘하는 것을 확인 할 수 있음.

단점: 모델 내부에서 사용하는 형태소 토큰을 알 수 없음.

긍/부정 분류 - 성능 평가

① 랜덤 추출한 데이터들 중 직접 라벨링하여 긍정 150개, 부정 150개 총 300개의 평가용 리뷰 파일 생성

review_text	manual_label	label_bin
내용의 깊이 없이 짜깁기해서 얼기설기 훑은 책	negative	0
책 안보는 청소년들 흥미 끌기용으로 적합하다.	negative	0
생각보다 기대이하임 돈주고 볼만한 가치는 없	negative	0
초반부에는 인물의 심리를 따라갈 수조차 없는,	negative	0
잘 읽다가 pc요소 종종 나와서 토가 나올것같	negative	0
별로다. 15살에 웹툰을 읽느라 시간을 다 보냈다	negative	0

② 앞에서 사용한 동일한 방식, 모델로 평가용 리뷰 파일의 긍/부정 이진 분류 수행

③ 혼동행렬 및 성능평가 지표 계산

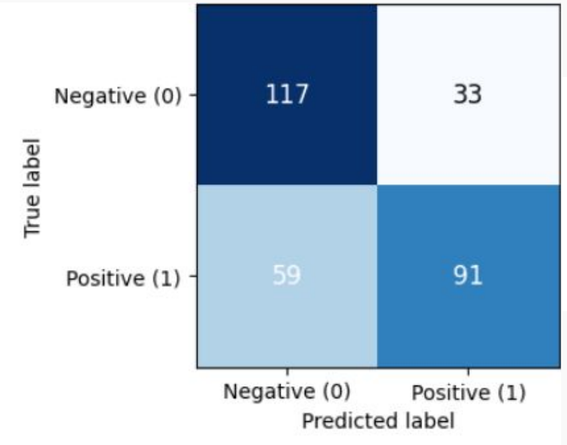

	precision	recall	f1-score	support
0	0.66	0.78	0.72	150
1	0.73	0.61	0.66	150
accuracy			0.69	300
macro avg	0.70	0.69	0.69	300
weighted avg	0.70	0.69	0.69	300

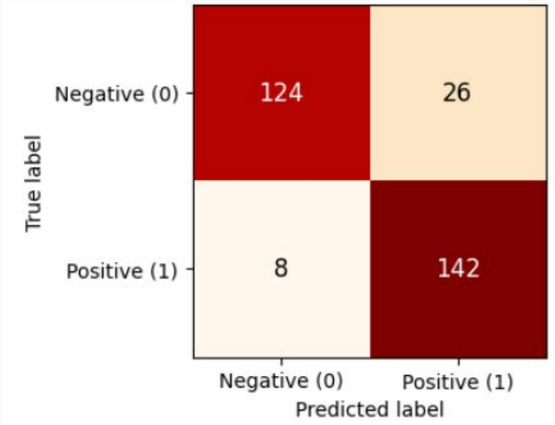

	precision	recall	f1-score	support
0	0.94	0.83	0.88	150
1	0.85	0.95	0.89	150
accuracy			0.89	300
macro avg	0.89	0.89	0.89	300
weighted avg	0.89	0.89	0.89	300

→ 리뷰의 긍/부정 분류는 KoELECTRA 모델의 **성능이 더 우수**함을 확인

IV. 결과 분석

기본 분석 & 시각화

1. 연도별 장르 비중 변화

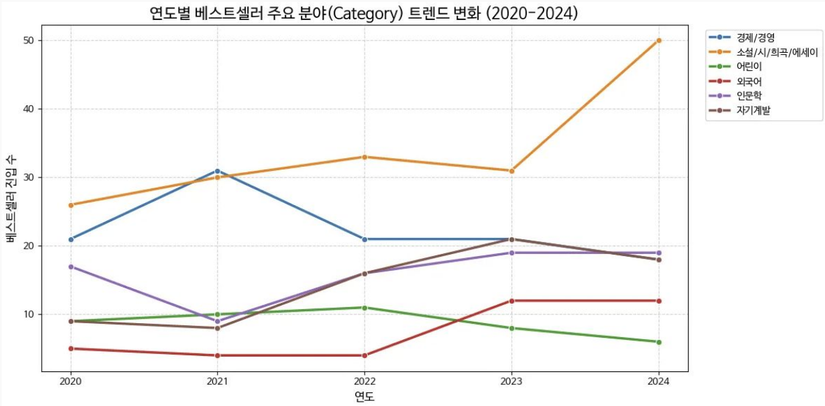

2. 평점 추이: 전반적으로 고평점

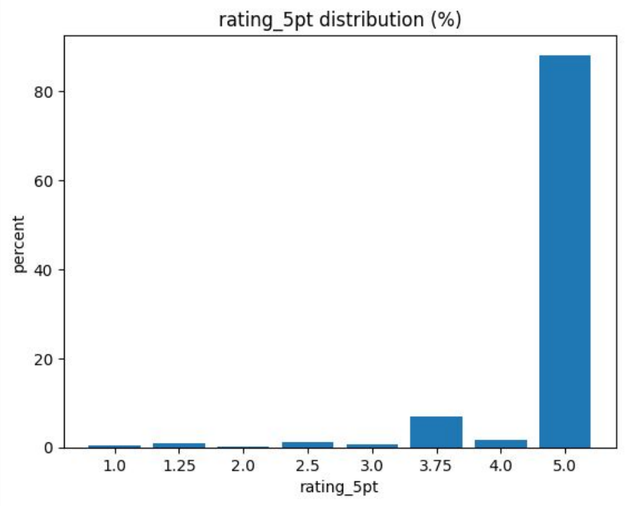

3. 감성지수 추이: 0~2점 사이 집중 분포 → 약한 긍정

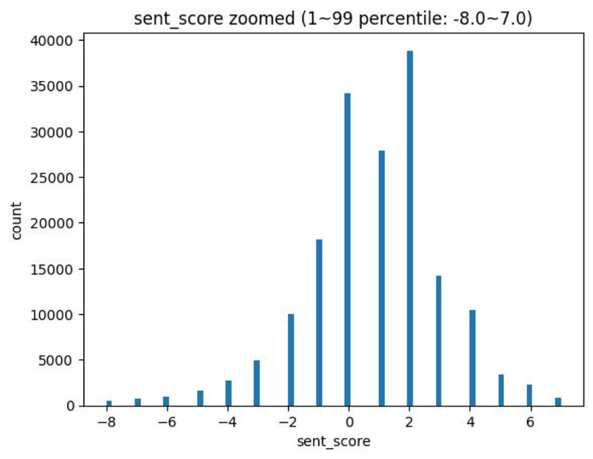

4. 평점과 감성지수의 상관관계

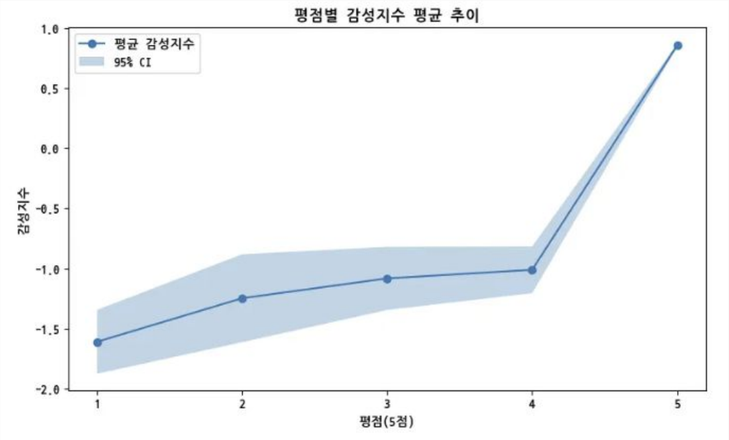

인사이트 도출

<지속 스테디셀러 vs 단발성 베스트셀러>

분류 기준

- **스테디**: 4–5년 연속 베스트셀러
- **트렌드**: 1년만 베스트셀러 후, 2년 이상 재등장 없음 (20–22년 대상)

분석 결과

- **연평균 리뷰 수**: 스테디 ↑ (지속적 관심)
- **평균 평점**: 스테디 ↑ (만족도 상대적 우위)
- **평균 감성점수**: 스테디 ≈ 트렌드
- **평균 리뷰 길이**: 트렌드 ↑ (후기형/설명형),
  스테디 ↓ (짧은 추천/누적형)

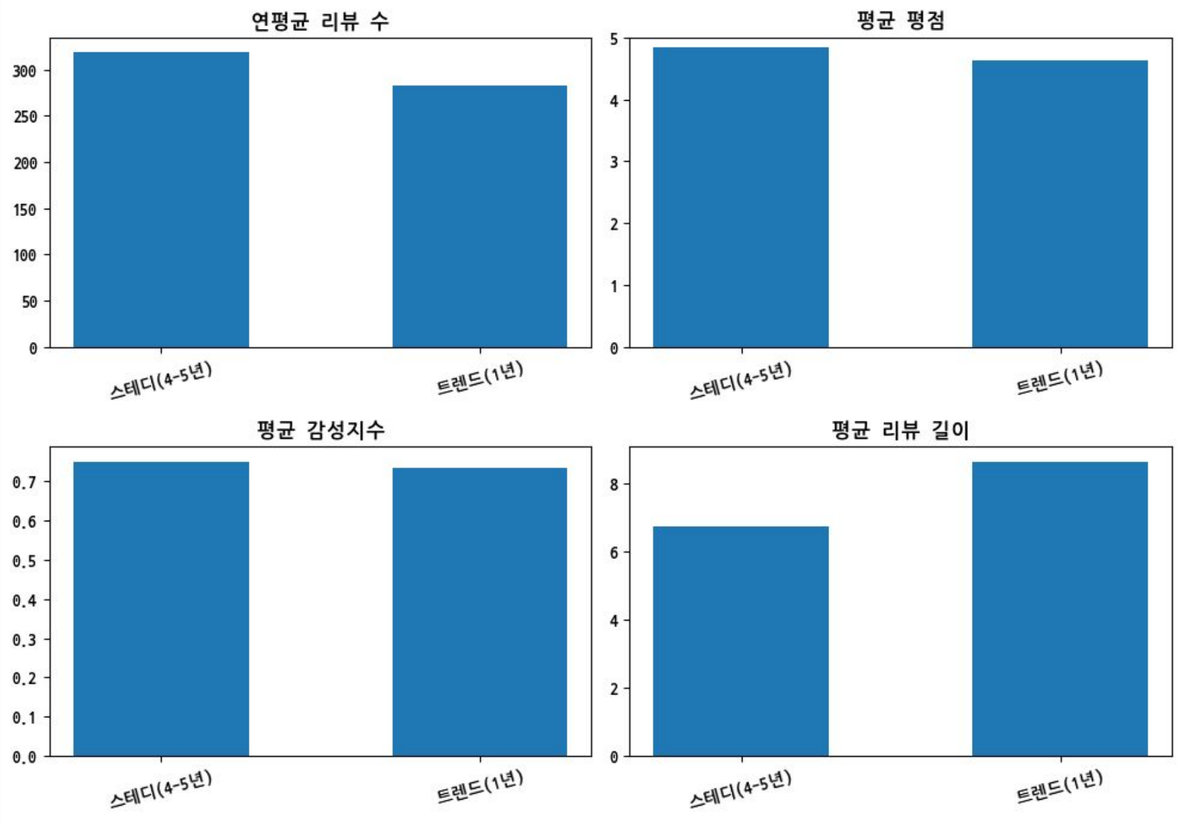

인사이트 도출

< 연도별 키워드 변화 (TOP 100) >

: 리뷰 빈도 상위 명사 키워드를 통해 **사회 이슈, 문화 관심사, 독서 주제의 변화 흐름**을 직관적으로 파악 가능

2020: 팬데믹의 시작과 콘텐츠 소비의 변화

- 코로나19로 인한 예민·차별 등 사회적 긴장/불안 정서가 리뷰에 반영됨
- 현실의 답답함 해소를 위한 넷플릭스·SF·삼국지 등 몰입도 높은 콘텐츠로의 비중 증가

2021: 투자 열풍과 공정성 논란

- 주식·투자·메타버스 등 재테크 관련 대중의 관심 증가
- 조국·검찰·공정·능력주의 등 정치·사회적 이슈가 두드러짐

2022: 사회적 논란과 심리적 피로감 해소 열망

- 대통령·부동산·국민 등 국가/정책 이슈의 지속
- 현실의 피로도가 높아지며 힐링 소설과 여행을 통해 마음 치유하려는 열망 증가

인사이트 도출

< 연도별 키워드 변화 (TOP 100) >

: 리뷰 빈도 상위 명사 키워드를 통해 **사회 이슈, 문화 관심사, 독서 주제의 변화 흐름**을 직관적으로 파악 가능

2023: 철학적 도서의 인기

- 집중·집중력·인사이트·경제학 등 **자기관리/학습/인문학적 지식** 키워드 등장
- 힐링·영화 같은 **일상 콘텐츠**가 공존

2024: '한강' 신드롬과 독서트렌드

- 노벨문학상 수상으로 소설/문학 분야의 강세 및 '독서 붐' 발생
- 'AI', '자본주의' 등 현대사회에 대한 관심도 증가

베스트셀러 거품(Bubble) 탐지 - 아이디어 배경

“많이 팔린다고 다 좋은 책일까?”

➔ 베스트셀러 순위는 높은데,
실제 리뷰 감성지수가 판매량을 따라가지 못하는 도서를 탐지

➔ 거품(Bubble) : 독자의 기대와 실제 만족도 사이의 격차가 과도하게 커진 상태

➔ <거품을 만드는 요소>

- SNS 광고·바이럴 중심의 급격한 관심증가
- 협찬 리뷰·체험단 리뷰 등 부풀려진 리뷰
- 과장된 광고에 비해 실제 책 내용은 실망

텍스트 기반 거품지수가 필요한 이유

➔ 기존 베스트셀러 지표는 ‘판매량’ 중심 = 실제 도서의 만족도 반영 불가

➔ 그렇다면, 리뷰 텍스트 기반 분석 지표는?

- 심리적 피로 빈도 증가
- 콘텐츠 실망 빈도 증가
- 몰입·재미 빈도
- 정서적 위로 빈도
- 평균 감성 점수

➔ 위 지표를 결합해 ‘거품 지수(Bubble Index)’를 계산

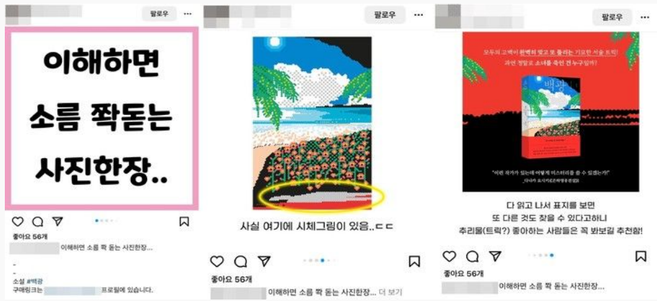

← 실제 SNS
도서 바이럴 게시물

베스트셀러 거품(Bubble) 탐지

< 기대 만족도 측정 지표 >

인기 지수	베스트셀러 순위 역정규화 0~1 사이의 값으로 계산	$\text{인기 지수} = 1 - \frac{\text{실제 순위} - 1}{\text{최대 순위} - 1}$
정규화 평점	알라딘/교보문고 평점 0~1 사이의 값으로 정규화	*알라딘 평점= 5점 만점 *교보 평점= 4점 만점
기대 만족도	두 지표를 통합한 가중 평균 값	$(w_1 \times \text{인기 지수}) + (w_2 \times \text{정규화 평점})$

< 실제 만족도 측정 방법 >

분석 기법	KoELECTRA 기반 긍/부정 분류 감성 분석 리뷰 텍스트 내 핵심 정서 단어 빈도 분석
분석 도구	KoELECTRA 모델을 활용한 정규화 *KoELECTRA를 사용한 이유: 감성 사전과 해당 모델의 성능 평가를 실시한 결과 KoELECTRA 의 성능이 더 높게 나타남.
결과지표	1. 감성 점수 = KoELECTRA 모델이 해당 리뷰를 '긍정'으로 분류할 확률 2. 정서 DNA = 리뷰 텍스트 내에서 반복되는 감정 키워드 빈도 기반 3. 버블 지수 = (평점 기반 기대 만족도)-(감성 점수 기반 실제 만족도)

베스트셀러 거품(Bubble) 탐지

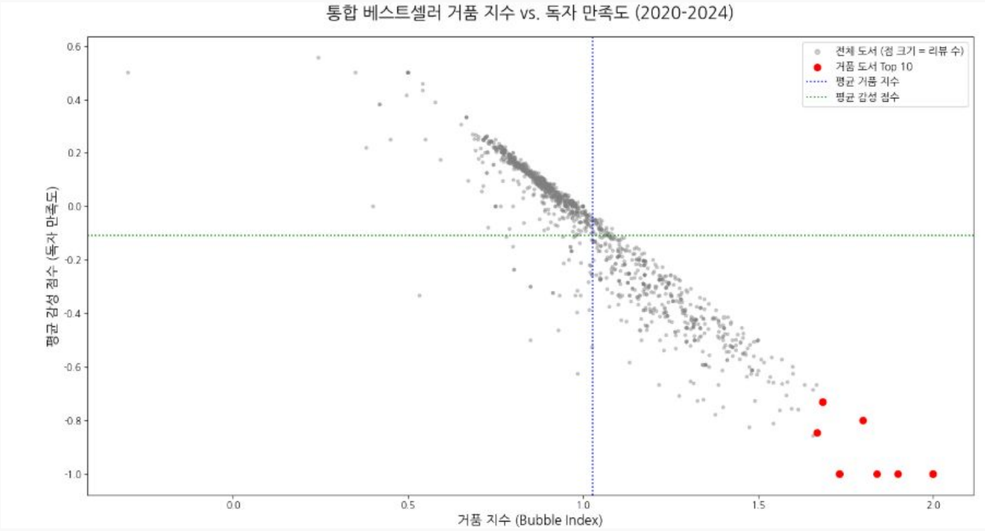

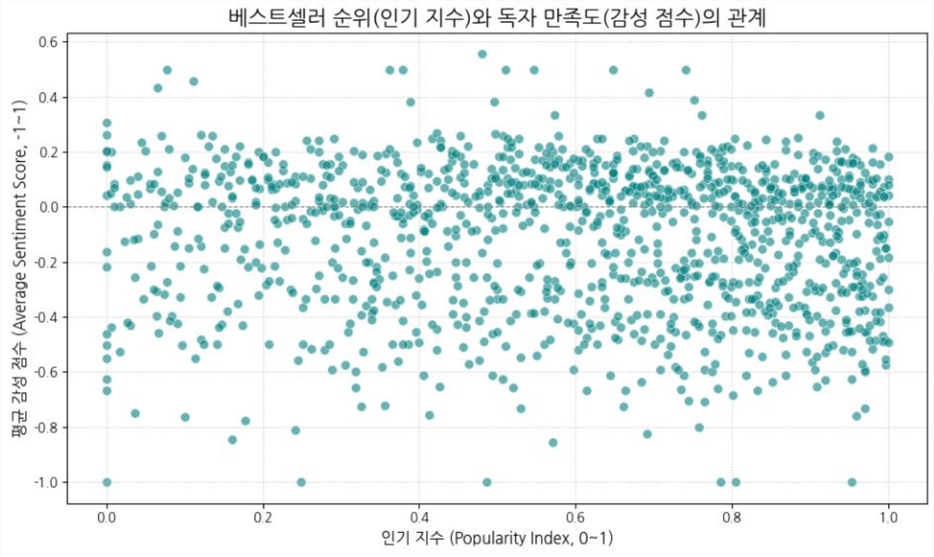

1. **거품 지수 vs 독자 만족도 (2020–2024)**
- X축: 거품 지수 (평점 – 감성 점수 차이)
- Y축: 평균 감성 점수 (독자 만족도)
- 거품 지수가 높을수록 독자 만족도는 낮아지는 경향

2. 베스트셀러 순위 vs 독자 만족도

- X축: 인기 지수 (판매량·순위 기반)
- Y축: 평균 감성 점수
- 피어슨 상관계수: **-0.0679**

"베스트셀러(많이 팔린 책) ≠ 독자에게 만족을 주는 책"

리뷰에 대한 토픽 추출(LDA) 및 유사도 기반 도서 추천

기존 장르별 군집 분류에 갇혀 있던 독자들에게, 장르 불문 토픽 유사 기반의 새로운 도서 추천 경험을 제시

➔ 기존 온/오프라인 서점은 '장르' 기반의 도서 분류

➔ 도서의 고유한 캐릭터를 '토픽'으로도 해석

➔ 독자에게 '표면적 유사도'가 아닌 '잠재적 유사도'를 제공

실제 서점의 '장르'별 도서 배치 사례

전체 리뷰에 대한 6개의 토픽 추출

도서명	1순위_정서	1순위_비중	T1_흥미_필요_편하	T2_기대_투자_주식	T3_도움_마음_공부	T4_마음_선물_최고	T5_좋아하_나오_기대	T6_느끼_유익_인간
1984	T1_흥미_필요	29.7	29.7	14.1	8.3	15.5	8.1	24.3
10배의법칙	T1_흥미_필요	29.3	29.3	17.2	14	12	12.5	15.1
10일만에끝내는해커스opi	T2_기대_투	27	16.9	27	23.8	10.7	8.3	13.3
117층나무집	T5_좋아하_	46.7	9.5	9.6	11.1	11.9	46.7	11.2
1212부와성공을부르는12	T1_흥미_필요	26.4	26.4	17.5	14.5	13.4	11.4	16.8
130층나무집	T5_좋아하_	49.6	8.8	8.6	10.2	11.9	49.6	10.9
143층나무집	T5_좋아하_	51.3	9.4	7.8	11	10.5	51.3	10.1

순위	토픽명(Key Emotion)	전체_평균_비중(%)	대표_도서_수(권)	설명
1	T2_기대_투자_주식	18.2	109	전체 460권 중 109권이 이 정서를 가장 강하게 띰
2	T3_도움_마음_공부	16.8	71	전체 460권 중 71권이 이 정서를 가장 강하게 띰
3	T4_마음_선물_최고	16.6	98	전체 460권 중 98권이 이 정서를 가장 강하게 띰
4	T5_좋아하_나오_기대	16.3	72	전체 460권 중 72권이 이 정서를 가장 강하게 띰
5	T6_느끼_유익_인간	16.1	48	전체 460권 중 48권이 이 정서를 가장 강하게 띰
6	T1_흥미_필요_편하	15.9	62	전체 460권 중 62권이 이 정서를 가장 강하게 띰

📊 [정서별 도서 점유율 현황]
- T2_기대_투자_주식: 109권 (23.7%)
- T4_마음_선물_최고: 98권 (21.3%)
- T5_좋아하_나오_기대: 72권 (15.7%)
- T3_도움_마음_공부: 71권 (15.4%)
- T1_흥미_필요_편하: 62권 (13.5%)
- T6_느끼_유익_인간: 48권 (10.4%)

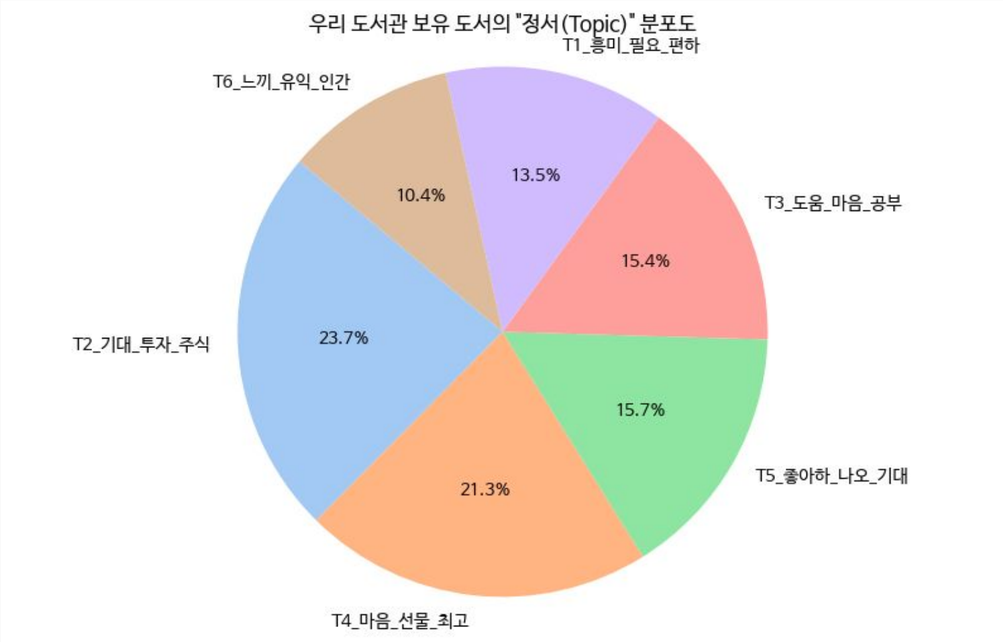

장르불문 토픽 유사도 기반 도서 추천

기준 도서: <강방천의관점> 경제/경영
ㄴ 주된 정서: T2_기대_투자_주식 (43.2%)

[AI 추천] 정서적 결(Mood)이 비슷한 도서 TOP 3:
경제/경영 1. <세븐테크> (유사도: 99.9%)
ㄴ 핵심 정서: T2_기대_투자_주식
경제/경영 2. <돈의시나리오> (유사도: 99.8%)
ㄴ 핵심 정서: T2_기대_투자_주식
인문 3. <코로나사피엔스> (유사도: 99.6%)
ㄴ 핵심 정서: T2_기대_투자_주식

기준 도서: <1984> 소설
ㄴ 주된 정서: T1_흥미_필요_편하 (29.7%)

[AI 추천] 정서적 결(Mood)이 비슷한 도서 TOP 3:
자기계발서 1. <럭키드로우> (유사도: 98.5%)
ㄴ 핵심 정서: T1_흥미_필요_편하
에세이 2. <사람에대한예의> (유사도: 98.1%)
ㄴ 핵심 정서: T6_느끼_유익_인간
에세이 3. <물고기는존재하지않는다> (유사도: 97.9%)
ㄴ 핵심 정서: T6_느끼_유익_인간

V. 최종 결론

결론

① 시대상이 반영된 도서 트렌드

- 연도별 상위 빈도 키워드 기반 : 사회적 분위기와 독자들의 주 관심사가 뚜렷하게 반영됨.

② 베스트셀러 순위 ≠ 독자 만족도

- 버블 탐지 모델 분석 결과, 베스트셀러 순위 ≠ '리뷰 텍스트 기반 만족도'
- '판매 순위'가 독서 경험의 질을 보장 X, 리뷰 기반 실질 만족도 지표가 더 중요함.

③ 리뷰 토픽 기반 도서 추천

- 단순 카테고리 분류를 넘어, 리뷰 텍스트 속 '정서의 결'이 비슷한 책들을 연결함.
- 전혀 다른 분야에서도 공통된 주제를 찾아내여 추천 범위를 확장함.

V. Appendix

한계점 및 해결방안

데이터 불균형 및 편향 가능성 도서별 리뷰 수와 연도별 선정 도서 수의 편차 존재 → 특정 도서의 데이터가 전체 분석 결과를 지배할 가능성 존재	- 두 플랫폼의 '**교집합**' 도서만을 대상으로 분석해 **교차검증된 데이터**만을 확보 - 리뷰 수가 많은 현상 자체를 그 해의 강력한 트렌드로 판단하여 인위적인 데이터 축소 없이 **원본 비율을 유지**
스테디셀러의 시계열 데이터 중복 베스트셀러의 리뷰를 전체 수집하여 전처리할 경우 과거 누적 리뷰가 중복으로 수집됨	- **작성일** 기준 연도별 필터링 - 누적리뷰가 아닌 해당 연도에 작성된 리뷰만 수집해 트렌드 분석의 무결성 확보
리뷰 데이터의 질적 편차 및 의미적 희소성 도서 리뷰 특성상 "재밌어요", "좋아요"와 같은 단답형, 형식적 리뷰 비중이 높음	- 대수의 법칙을 통한 거시적 경향성 파악 - 전처리 과정을 통한 노이즈 최소화

감사합니다

2025-2 텍스트마이닝 TMI조